МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ

«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №3

Специальность ИИ(3)

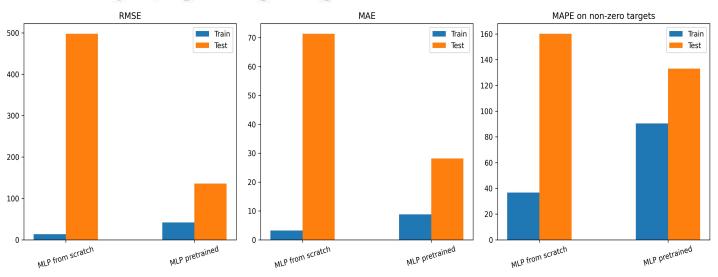
Выполнил А. Ю. Кураш, студент группы ИИ-24

Проверил Андренко К.В, Преподаватель-стажер кафедры ИИТ, $_{\rm L}$ $_{\rm L}$

Цель: научиться осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода

Общее задание

- 1. Взять за основу любую сверточную или полносвязную архитектуру с количеством слоев более 3. Осуществить ее обучение (без предобучения) в соответствии с вариантом задания. Получить оценку эффективности модели, используя метрики, специфичные для решаемой задачи (например, МАРЕ для регрессионной задачи или F1/Confusion matrix для классификационной).
- 2. Выполнить обучение с предобучением, используя автоэнкодерный подход, алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев с использованием автоэнкодера выбрать самостоятельно.
- 3. Сравнить результаты, полученные при обучении с/без предобучения, сделать выводы.
- 4. Выполните пункты 1-3 для датасетов из ЛР 2.
- 5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.



8	https://archive.ics.uci.edu/dataset/162/forest	регрессия	area
	+fires		

Выполнение:

Код программы

import os import math import random import numpy as np import pandas as pd from sklearn.model_selection import train_test_split from sklearn.preprocessing import StandardScaler, OneHotEncoder import torch import torch.nn as nn from torch.utils.data import TensorDataset, DataLoader

seed = 42
random.seed(seed)
np.random.seed(seed)
torch.manual_seed(seed)

--- Параметры (можете менять)

```
DATA URL = "https://archive.ics.uci.edu/ml/machine-learning-databases/forest-fires/forestfires.csv"
BATCH SIZE = 32
EPOCHS MLP = 200
EPOCHS AE PER LAYER = 120
EPOCHS FINE TUNE = 150
LR MLP = 1e-3
LR FINE = 5e-4
WEIGHT DECAY = 1e-5
HIDDEN SIZES = [64, 32, 16, 8] # архитектура > 3 слоёв
device = torch.device("cuda" if torch.cuda.is available() else "cpu")
# --- Загрузка
defload data(path or url=DATA URL):
  if os.path.exists(path or url):
    df = pd.read csv(path or url)
  else:
    # скачиваем по URL (если есть интернет)
    df = pd.read csv(path or url)
  return df
df = load data()
# --- Предобработка
df['month'] = df['month'].astype(str)
df['day'] = df['day'].astype(str)
cat = df[['month', 'day']]
enc = OneHotEncoder(sparse output=False, drop='first')
cat enc = enc.fit transform(cat)
num = df[['X','Y','FFMC','DMC','DC','ISI','temp','RH','wind','rain']].values.astype(float)
X raw = np.hstack([num, cat enc])
y raw = df['area'].values.astype(float)
y \log = np.\log 1p(y raw)
scaler = StandardScaler()
X = \text{scaler.fit transform}(X \text{ raw})
X train, X test, y train, y test, ylog train, ylog test =
  train test split(X, y raw, y log, test size=0.2, random state=seed
)
X train t = torch.tensor(X train, dtype=torch.float32)
X test t = torch.tensor(X test, dtype=torch.float32)
ytrain t = torch.tensor(ylog train, dtype=torch.float32).unsqueeze(1)
ytest t = torch.tensor(ylog test, dtype=torch.float32).unsqueeze(1)
train ds = TensorDataset(X train t, ytrain t)
test ds = TensorDataset(X test t, ytest t)
train loader = DataLoader(train ds, batch size=BATCH SIZE, shuffle=True)
test loader = DataLoader(test ds, batch size=BATCH SIZE, shuffle=False)
```

```
# --- Вспомогательные функции
def train model(model, train loader, epochs=100, lr=1e-3, weight decay=0.0):
  model = model.to(device)
  opt = torch.optim.Adam(model.parameters(), lr=lr, weight decay=weight decay)
  criterion = nn.MSELoss()
  for epoch in range(epochs):
    model.train()
    for xb, yb in train loader:
      xb = xb.to(device); yb = yb.to(device)
      opt.zero grad()
      out = model(xb)
      loss = criterion(out, yb)
      loss.backward()
      opt.step()
  return model
def evaluate model(model, X t, y raw true):
  model.eval()
  with torch.no grad():
    pred log = model(X t.to(device)).cpu().numpy().reshape(-1)
  pred area = np.expm1(pred log)
  true area = y raw true.reshape(-1)
  eps = 1e-6
  rmse = np.sqrt(np.mean((pred area - true area)**2))
  mae = np.mean(np.abs(pred area - true area))
  nonzero mask = true area > 0
  if nonzero mask.sum() > 0:
    mape = np.mean(np.abs((pred area[nonzero mask] - true area[nonzero mask]) /
(true area[nonzero mask] + eps))) * 100
  else:
    mape = float('nan')
  return {'RMSE': rmse, 'MAE': mae, 'MAPE % on nonzero targets': mape, 'Pred mean':
pred area.mean(), 'True mean': true area.mean()}
# --- Модель МLР (без предобучения)
class MLP(nn.Module):
  def_init_(self, input dim, hidden sizes):
    super()._init_()
    layers = []
    prev = input dim
    for h in hidden sizes:
       layers.append(nn.Linear(prev,h))
      layers.append(nn.ReLU())
      prev = h
    layers.append(nn.Linear(prev.1))
    self.net = nn.Sequential(*layers)
  def forward(self,x):
    return self.net(x)
input \dim = X.shape[1]
torch.manual seed(seed)
```

```
model plain = MLP(input dim=input dim, hidden sizes=HIDDEN SIZES)
model plain = train model(model plain, train loader, epochs=EPOCHS MLP, lr=LR MLP,
weight decay=WEIGHT DECAY)
metrics plain train = evaluate model(model plain, X train t, y train)
metrics plain test = evaluate model(model plain, X test t, y test)
# --- Autoencoders (layer-wise pretraining)
class Autoencoder(nn.Module):
  def_init_(self, in dim, hidden dim):
    super()._init_()
    self.encoder = nn.Sequential(nn.Linear(in dim, hidden dim), nn.ReLU())
    self.decoder = nn.Sequential(nn.Linear(hidden dim, in dim))
  def forward(self,x):
    z = self.encoder(x)
    out = self.decoder(z)
    return out
  def encode(self,x):
    return self.encoder(x)
def train autoencoder(ae, data tensor, epochs=100, lr=1e-3):
  ae = ae.to(device)
  opt = torch.optim.Adam(ae.parameters(), lr=lr)
  criterion = nn.MSELoss()
  ds = TensorDataset(data tensor, data tensor)
  loader = DataLoader(ds, batch size=BATCH SIZE, shuffle=True)
  for epoch in range(epochs):
    ae.train()
    for xb, in loader:
      xb = xb.to(device)
      opt.zero grad()
      out = ae(xb)
      loss = criterion(out, xb)
      loss.backward()
      opt.step()
  return ae
# layer-wise pretraining на X train
X train tensor = X train t.clone().to(device)
enc sizes = HIDDEN SIZES
encoders = []
current input = X train tensor
for h in enc sizes:
  in dim = current input.shape[1]
  ae = Autoencoder(in dim, h)
  ae = train autoencoder(ae, current input, epochs=EPOCHS AE PER LAYER, lr=1e-3)
  with torch.no grad():
    encoded = ae.encode(current input.to(device)).cpu()
  encoders.append(ae.encoder) # сохраним для инициализации
  current input = torch.tensor(encoded, dtype=torch.float32)
# --- Сборка финальной сети с инициализацией из энкодеров
class MLP Pretrained(nn.Module):
```

```
def_init_(self, input_dim, encoders):
    super()._init_()
    layers = []
    prev = input dim
    for enc in encoders:
      lin layer = nn.Linear(prev, enc[0].out features)
      lin layer.weight.data = enc[0].weight.data.clone()
      lin layer.bias.data = enc[0].bias.data.clone()
      layers.append(lin layer)
      layers.append(nn.ReLU())
      prev = enc[0].out features
    layers.append(nn.Linear(prev, 1))
    self.net = nn.Sequential(*layers)
  def forward(self, x):
    return self.net(x)
torch.manual seed(seed)
model pre = MLP Pretrained(input dim=input dim, encoders=encoders).to(device)
model pre = train model(model pre, train loader, epochs=EPOCHS FINE TUNE, lr=LR FINE,
weight decay=WEIGHT DECAY)
metrics pre train = evaluate model(model pre, X train t, y train)
metrics pre test = evaluate model(model pre, X test t, y test)
# --- Вывод результатов
import ison
results = {
  "MLP from scratch train": metrics plain train,
  "MLP from scratch test": metrics plain test,
  "MLP pretrained train": metrics pre train,
  "MLP pretrained test": metrics pre test,
  "n samples": len(df),
  "zero fraction": float((y raw = 0).mean())
# Безопасный вывод (float32 \rightarrow float)
print(json.dumps(results, indent=2, default=float))
import matplotlib.pyplot as plt
# --- Подготовка данных для графика
metrics train = [metrics plain train, metrics pre train]
metrics test = [metrics plain test, metrics pre test]
labels = ['MLP from scratch', 'MLP pretrained']
# RMSE, MAE, MAPE
rmse train = [m['RMSE'] for m in metrics train]
mae train = [m['MAE']] for m in metrics train
mape train = [m['MAPE % on nonzero targets'] for m in metrics train]
```

```
rmse test = [m['RMSE'] \text{ for m in metrics test}]
mae test = [m['MAE'] \text{ for m in metrics test}]
mape test = [m]'MAPE \% on nonzero targets'] for m in metrics test]
x = np.arange(len(labels))
width = 0.25
# --- Создание фигуры
fig, ax = plt.subplots(1, 3, figsize=(15,5))
#RMSE
ax[0].bar(x - width/2, rmse train, width, label='Train')
ax[0].bar(x + width/2, rmse test, width, label='Test')
ax[0].set xticks(x)
ax[0].set xticklabels(labels, rotation=15)
ax[0].set title('RMSE')
ax[0].legend()
#MAE
ax[1].bar(x - width/2, mae train, width, label='Train')
ax[1].bar(x + width/2, mae test, width, label='Test')
ax[1].set xticks(x)
ax[1].set xticklabels(labels, rotation=15)
ax[1].set title('MAE')
ax[1].legend()
# MAPE
ax[2].bar(x - width/2, mape train, width, label='Train')
ax[2].bar(x + width/2, mape test, width, label='Test')
ax[2].set xticks(x)
ax[2].set xticklabels(labels, rotation=15)
ax[2].set title('MAPE on non-zero targets')
ax[2].legend()
plt.tight layout()
plt.savefig("forestfires metrics.png", dpi=300)
plt.show()
Console:
 "MLP from scratch train":
  { "RMSE": 13.426600705431689,
  "MAE": 3.2240595635113705,
  "MAPE % on nonzero targets": 36.77655896285223,
  "Pred mean": 8.280572891235352,
  "True mean": 11.132130750605326
 "MLP from scratch test":
  { "RMSE": 497.6347677252394,
  "MAE": 71.3220543794948,
  "MAPE % on nonzero targets": 160.14050673069798,
  "Pred mean": 55.2412109375,
  "True mean": 19.658461538461538
```

```
"MLP_pretrained_train":
{ "RMSE": 41.99306801892418,
   "MAE": 8.817244105785628,
   "MAPE_%_on_nonzero_targets": 90.42972262781537,
   "Pred_mean": 4.5474090576171875,
   "True_mean": 11.132130750605326
},

"MLP_pretrained_test":
   { "RMSE": 135.8030665124041,
   "MAE": 28.188940353749135,
   "MAPE_%_on_nonzero_targets": 133.09456676887302,
   "Pred_mean": 11.211857795715332,
   "True_mean": 19.658461538461538
},

"n_samples": 517,
   "zero_fraction": 0.47775628626692457
}
```

Вывод: Я научился применять предобучение с помощью автоэнкодера.